거래분류 에이전트 v8 성능 검증

실지출 트래커 · 2026년 11월 3일 · 정답 데이터 569건 직접 라벨링 · 모든 비교는 Claude Haiku 5.5 기준

1. 한눈에 보기

에이전트 v8 (규칙 + 스킬)
69%
372건 중 255건 정답

기존 에이전트 (기본 프롬프트)
55%
372건 중 206건 · v8이 **+14%p**

Haiku 모델 단독 (기존 API)
63%
같은 회차 234건 · v8이 **+6%p**

> **결론.** 같은 Haiku 5.5 모델로, 에이전트 v8은 기존 에이전트보다 **49건 더** 맞혔습니다(206 → 255). 같은 회차의 Haiku 단독 분류보다도 21건 더 맞혔고, 네 번 돌린 Haiku 단독 결과 중 가장 좋았던 67%보다도 높습니다. 비용은 1회 채점에 $0.06로 기존 에이전트($0.07)와 비슷하고, 묶음당 처리 시간은 약 128초에서 94초로 줄었습니다.

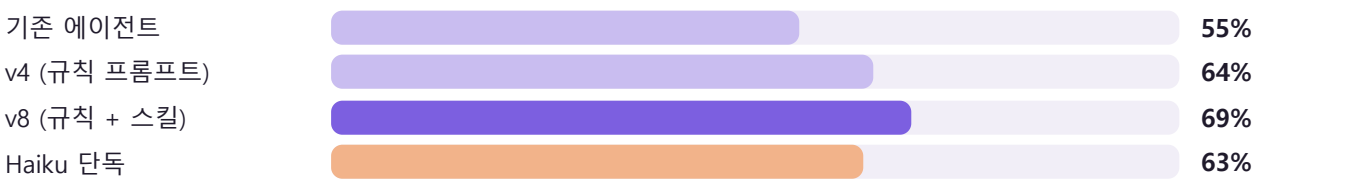
2. 어떻게 검증했나

- **데이터:** 실제 토스뱅크 3개월 거래내역 570건. 사용자가 클릭 도구로 한 건씩 정답을 매겼습니다(나간 돈 372건, 들어온 돈 197건, 1건 미표시).
- **채점 대상:** 나간 돈 372건의 카테고리 13개(식비, 편의점, 술, 유흥, 구독료, 교통비, 쇼핑, 생활, 데이트, 여행, 송금, 기타, 제외).
- **공정성(3겹 교차 검증):** 거래를 세 묶음으로 나누고, 한 묶음을 시험 볼 때는 그 묶음의 정답과 **같은 가게의 정답을 모두 가렸습니다.** 이렇게 세 번 돌려 전체를 채점했습니다.
- **같은 조건:** 셋 다 같은 모델(Haiku 5.5), 같은 정답, 같은 거래 조회 도구를 씁니다. 다른 것은 에이전트의 지시문(프롬프트)과 스킬뿐입니다.

3. 버전별 결과

버전	바뀐 것	전체	가게 결제	페이·송금	비용
기존 에이전트	기본 프롬프트	206 (55%)	173/262 (66%)	33/110 (30%)	$0.07
v4	규칙 프롬프트	238 (64%)	189/262 (72%)	49/110 (45%)	$0.09
v8	**규칙 + 분류 스킬**	**255 (69%)**	**214/262 (82%)**	**41/110 (37%)**	**$0.06**
Haiku 단독	에이전트 없이 한 번에 분류	234 (63%)	199/262 (76%)	35/110 (32%)	$0.05

페이·송금 = 토스페이·카카오페이·결제대행사·사람 이름처럼 이름만으로 용도를 알 수 없는 거래. 가게 결제 = 그 밖의 거래.



4. 카테고리별 정답률

카테고리 (정답 건수)	기존 에이전트	v4	v8	Haiku 단독
편의점 (140)	**90 (64%)**	**106 (76%)**	**133 (95%)**	**107 (76%)**
유흥 (71)	35 (49%)	47 (66%)	45 (63%)	41 (58%)
식비 (50)	39 (78%)	33 (66%)	34 (68%)	35 (70%)
교통비 (34)	23 (68%)	27 (79%)	24 (71%)	19 (56%)
데이트 (30)	2 (7%)	7 (23%)	3 (10%)	11 (37%)
기타 (19)	6 (32%)	5 (26%)	4 (21%)	4 (21%)
술 (11)	2 (18%)	4 (36%)	3 (27%)	7 (64%)
여행 (7)	3 (43%)	3 (43%)	3 (43%)	4 (57%)
구독료·생활·쇼핑 (10)	6	6	6	6

- **가장 큰 개선은 편의점입니다(64% → 95%).** 스킬에 "마트·슈퍼·할인점·생협 매점은 편의점"이라는 규칙과 법인명 가게를 읽는 법을 넣은 효과입니다. 정답에서 가장 많은 카테고리(140건)라 전체 점수를 크게 끌어올렸습니다.
- **유흥·교통비**도 기존 에이전트보다 좋아졌습니다.
- **데이트는 여전히 약점입니다(30건 중 3건).** 데이트를 유흥·식비로 고른 경우가 25건으로, 남은 오답 중 가장 큰 덩어리입니다.

5. 에이전트는 자기 확신을 안다

v8이 낸 확신도	건수	정답률
high (단서 분명)	186	161 (87%)
medium (추리함)	93	71 (76%)
low (단서 거의 없음)	93	23 (25%)

확신도가 높을수록 실제로 더 잘 맞습니다. 그래서 **high·medium은 자동으로 확정**하고 **low만 사용자에게 "확정 필요"로 물어보는** 방식이 가능합니다. 이 경우 자동 확정 279건의 정답률은 **83%**이고, 사용자는 나머지 93건만 확인하면 됩니다.

6. 해석할 때 주의할 점

- **회차마다 조금씩 달라집니다.** Haiku 단독은 네 번 돌렸을 때 63~67%였습니다. v8은 이 범위의 가장 높은 값보다도 높지만, v8은 한 번만 쟀습니다.
- **설정 차이:** 기존 에이전트와 v4는 채점 코드가 effort를 medium으로 정했고, v8은 Console에서 정한 low로 돌았습니다. v8은 더 적게 생각하고도 더 잘 맞혔습니다.
- **페이·송금은 v4가 더 좋았습니다(45% vs 37%).** v8은 가게 결제에서 크게 이기고 페이·송금에서는 v4보다 조금 졌습니다.
- **사용자 한 명의 3개월 데이터입니다.** 다른 사용자에게서도 같은 결과가 나오는지는 따로 확인해야 합니다.
- 스킬에는 정답에 나온 가게 이름을 넣지 않았습니다. 점수는 일반 규칙만으로 낸 실력입니다.

7. 다음 단계

- **데이트 잡기:** 그날의 거래 흐름(식사 → 카페 → 놀거리)을 한 번에 보여주는 도구와 스킬 보강.
- **메모리 저장소:** 사용자가 고친 결과를 복습 세션이 습관 규칙으로 정리하고, 분류 세션은 그 메모를 읽기만 합니다. 공정하게 재려면 정답의 3분의 2로 배우고 3분의 1로 시험합니다.
- **확정 필요:** low만 사용자에게 묻고, 고른 결과를 다시 학습에 씁니다.

채점 도구: `python -m app.agent.evaluate --db data/eval.db --engine both` (v8은 AGENT_VERSION=8로 버전 고정) · 들어온 돈 종류 분류(Haiku 단독)는 197건 중 193건(98%) 정답.